

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS



ALMACENES Y MINERÍA DE DATOS

EXÁMEN 4: DETECCIÓN DE OUTLIERS I

Alumnos:

- Méndez Ávila Luis Geovanni 317143980
- Paredes Zamudio Luis Daniel 318159926
- Sánchez Rosas Roberto Samuel 318355159

Profesora: L. en C.C. Jessica Santizo Galicia

27 de Mayo de 2026

Índice

1. ¿Que es un Outlier?	2
1.1. La Z-score y el IQR para detectar outliers	2
1.2. ¿Por qué es importante detectar los outliers?	3
1.3. Outliers y Ruido	4
2. Categorización de Outliers	4
2.1. Outliers Globales	4
2.2. Outliers Contextuales	4
2.3. Outliers Colectivos	4
3. Clustering	5
3.1. ¿De qué nos sirven los clústers?	5
4. Algoritmos de Clustering	6
4.1. Términos Generales de los Algoritmos de Clústering	6
4.1.1. Ejemplo Corto de Clustering	6
4.2. La Distancia Euclídea	6
5. K-Means	7
5.1. Los Centroides	7
5.2. La Inercia de K-Means	8
5.3. Visualizando K-Means	8
5.4. Ejemplo de Uso: El consumo eléctrico en hogares	10
5.5. La Regla del Codo	14
5.5.1. Ejemplo usando el método del codo	14

1. ¿Que es un Outlier?

Outlier

Es un objeto que tiene características diferentes de la mayoría de otros del dataset con el que estemos trabajando. También puede ser un valor inusual con respecto a los valores típicos de una variable.

Por ejemplo, si tenemos un dataset con la información de la altura de un grupo de personas, y el promedio es de 1.80 metros, un outlier sería ver un valor de 2.15 metros.

La naturaleza de los outliers es dual, así como pueden ser el resultado de errores de medición o entrada de datos, también pueden representar eventos genuinos pero poco frecuentes que aún nos pueden dar información valiosa del conjunto de datos. [6]




Figura 1: Visualización de outliers

1.1. La Z-score y el IQR para detectar outliers

Los outliers se detectan mediante su 'Z-score', que es una medida de cuántas desviaciones estándar un dato se encuentra por encima o por debajo de la media del conjunto de datos. Un valor de Z-score mayor a 3 o

menor a -3 generalmente se considera un outlier, aunque este umbral puede ajustarse según el contexto y la naturaleza de los datos. Esta calificación se calcula usando la fórmula:

$$Z = \frac{X - \mu}{\sigma}$$

Donde:

- X es el valor del dato que se está evaluando,
- μ es la media del conjunto de datos,
- σ es la desviación estándar del conjunto de datos.

Otra forma de describirlo es mediante el rango intercuartílico (IQR), que se calcula como la diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1) de los datos. Un dato se considera un outlier si está por debajo de $Q1 - 1.5 \times IQR$ o por encima de $Q3 + 1.5 \times IQR$.

Calcularlo es más trivial que el Z-score, pero es menos preciso, ya que no toma en cuenta la distribución de los datos, sino solo su posición relativa a los cuartiles. Se calcula como:

$$IQR = Q3 - Q1$$

Donde:

- $Q1$ es el primer cuartil (25 % de los datos por debajo de este valor),
- $Q3$ es el tercer cuartil (75 % de los datos por debajo de este valor).

1.2. ¿Por qué es importante detectar los outliers?

Si estos valores no se identifican ni procesan de una manera adecuada perjudica considerablemente los análisis estadísticos que se hagan de nuestros datos, ya que puede sesgar el modelos, reducir su precisión y/o comprometer su interpretabilidad.

Sin embargo la decisión de cómo manejar un outlier debe precederse por una investigación sobre *por qué existe*. Si un outlier es claramente el resultado de un error su eliminación o corrección es justificada. Sin embargo, si el outlier representa un evento genuino y válido, pero tal vez menos probable, debe ser considerado cuidadosamente o incluso aprovechado para obtener información valiosa. [3]

1.3. Outliers y Ruido

Algo que vale la pena recalcar es que un outlier **no es lo mismo** que el ruido. Mientras que el ruido son datos incorrectos o inconsistentes que restan la calidad del modelo que se vaya a crear, un outlier es más un valor que es posible pero muy poco frecuente.

2. Categorización de Outliers

2.1. Outliers Globales

Son los outliers menos específicos. Son eventos que se desvían significativamente del resto del dataset. Por ejemplo, un conjunto de datos de edad de personas en una empresa y un dato anómalo de 150 años.

2.2. Outliers Contextuales

Estos eventos se consideran atípicos según el contexto específico bajo el que se vayan a tratar. Por ejemplo, si nuestro dataset es sobre temperaturas en un estado a lo largo del año, un valor de 30°C es normal en verano, pero atípico en invierno.

2.3. Outliers Colectivos

Como su nombre lo dice, son eventos que aunque de manera individual no parecen ser anómalos, en conjunto si representan una anomalía. Por ejemplo, el rechazo de envío de un paquete de una computadora a otra se considera normal, pero si varias computadoras continúan enviando paquetes rechazados unas a otras, el conjunto se debería considerar como outlier colectivo. [4]




Figura 2: Visualización de tipos de Outliers

3. Clustering

Clustering

El clustering es una técnica de aprendizaje automático no supervisado que busca dividir el dataset en el que se este trabajando en grupos, a los que llamaremos clústers, en donde los elementos que se encuentran dentro de uno son lo más similares entre si y lo más distintos posibles o los de otro clúster.

Como es un método no supervisado no se necesita que los datos tengan etiquetas, clasificaciones previas o ejemplos de entrenamiento, si no que más bien lo que se busca es encontrar la distancia matemática (o similitud) entre cada dato para agruparlos lo más correctamente posible.

3.1. ¿De qué nos sirven los clústers?

- **Descubrir patrones ocultos:** Ayuda a revelar relaciones, estructuras y agrupaciones naturales dentro de los datos que no son evidentes a simple vista.

- **Simplificar información compleja:** Permite dividir y resumir grandes volúmenes de datos ruidosos en subgrupos más pequeños, homogéneos y manejables.
- **Exploración y descubrimiento:** Es sumamente útil para encontrar grupos de datos o categorías que eran previamente desconocidas por los analistas.

4. Algoritmos de Clustering

4.1. Términos Generales de los Algoritmos de Clústering

1. El algoritmo evalúa cada registro del conjunto de datos tomando en cuenta sus características como si fueran coordenadas de un punto en el espacio.
2. Luego, usamos métricas (como la distancia euclídea o la correlación) para medir qué tan cerca están esos puntos unos de otros
3. Con base en esta proximidad, el algoritmo asocia los puntos de modo que se minimice la distancia entre los elementos de un mismo grupo (haciéndolos muy compactos y similares) y se maximice la separación con los demás grupos.

4.1.1. Ejemplo Corto de Clustering

Digamos que tenemos un dataset de compras de un supermercado. Cada entrada en el conjunto se refiere a lo que compra una persona y queremos detectar grupos basados en clustering en base a esos datos. Entonces el algoritmo puede agrupar en 'compradores frecuentes', 'compradores nuevos', 'compradores de un solo artículo', etc. Y en base a estas métricas el supermercado puede encontrar patrones de los artículos más vendidos, etc.

4.2. La Distancia Euclídea

Como mencionábamos, una de las métricas más comunes para medir la similitud entre puntos es la distancia euclídea. Esta se calcula usando la fórmula:

$$d(P, Q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

Donde: - P y Q son dos puntos en un espacio n -dimensional, representados por sus coordenadas p_i y q_i respectivamente. - n es el número de dimensiones o características que describen cada punto.

La distancia euclídea mide la longitud del segmento de línea recta entre los puntos P y Q en el espacio

n-dimensional. Cuanto menor sea esta distancia, más similares son los puntos entre sí.

5. K-Means

El algoritmo de K-Means es uno de los métodos de clustering más populares y ampliamente utilizados. Su objetivo es dividir un conjunto de datos en k clústers distintos, donde k es un número predefinido por el usuario, minimizando la suma euclídea de las distancias al cuadrado entre los puntos. Funciona de la siguiente manera:

- Tomamos k datos (o puntos) aleatorios como los centros iniciales (o *centroides*) de cada clúster.
- Asignamos el resto de los datos a el clúster más cercano calculando su distancia euclídea a cada centro y asignándolo al de menor distancia.
- Una vez que todos los datos han sido asignados a un clúster, el algoritmo recalcula los centros de cada clúster tomando la media de los puntos asignados a ese clúster.
- Repetimos los pasos de asignación y recalcule de centros hasta que las asignaciones de los puntos no cambien significativamente o se alcance un número máximo de iteraciones.

5.1. Los Centroides

Mencionamos antes que éstos son los puntos que representan el centro de cada clúster. Se calculan tomando la media de las coordenadas de los puntos asignados a cada clúster, siendo así la 'coordenada promedio' de los puntos dentro del clúster. Matemáticamente, se ve de la siguiente manera:

$$\mu_i = \frac{1}{|S_i|} \sum_{x \in S_i} x$$

Donde:

- μ_i es el centroide del clúster i ,
- S_i es el conjunto de puntos asignados al clúster i
- $|S_i|$ es el número de puntos en el clúster i ,
- x representa cada punto dentro del clúster i .

5.2. La Inercia de K-Means

Otro objetivo de K-Means es minimizar la suma de las distancias al cuadrado entre cada punto y el centroide de su clúster asignado, esto para saber que tan dispersos están los datos respecto a su centroide. Matemáticamente, esto se expresa como

$$\sum_{j=1}^k \sum_{x \in S_j} d(x, \mu_j)^2$$

Donde:

- S_j es el conjunto de puntos asignados al clúster j ,
- μ_j es el centroide del clúster j ,
- $d(x, \mu_j)$ es la distancia entre el punto x y el centroide μ_j .

5.3. Visualizando K-Means

Por ejemplo, en las siguientes imágenes tenemos un dataset con una n cantidad de datos. Vamos a tomar $k = 3$ y seleccionamos 3 puntos aleatorios y los marcamos con azul, verde y amarillo. De esto creamos los primeros clústeres basándonos en la distancia de cada punto al centroide. Luego, recalculamos los centroides tomando la media de los puntos asignados a cada clúster y repetimos el proceso hasta que los clústeres no cambien significativamente. [1]




Figura 3: Inicialización de K-Means con $k = 3$




Figura 4: Clústeres Iniciales




Figura 5: Centroides recalculados




Figura 6: Clústeres Finales

5.4. Ejemplo de Uso: El consumo eléctrico en hogares

Para ilustrar el funcionamiento de k-means en la detección de datos atípicos, analizaremos un dataset real de consumo eléctrico doméstico, proveniente del [repositorio UCI](#). Este dataset contiene mediciones minuto a minuto de la potencia activa consumida y el voltaje registrado en una vivienda francesa desde Diciembre de 2006 hasta Noviembre de 2010.

Al aplicar k-means a este dataset, podemos identificar patrones de consumo y detectar posibles outliers que podrían indicar anomalías en el consumo eléctrico, como picos inusuales o caídas repentinas.

1. **Selección y limpieza de variables:** Se utilizan dos variables principales:

- `Global_active_power` (potencia activa global, en kW)
- `Voltage` (voltaje de la red, en V) Se eliminan valores nulos y se convierten los datos a formato numérico.

2. **Escalamiento:** Dado que ambas variables tienen escalas muy distintas, se normalizan para evitar que una domine el análisis de distancias. Usaremos `StandardScaler` de `sklearn.preprocessing` para centrar los datos en torno a la media y escalar a la unidad de varianza.

Nota sobre StandardScaler

Nota: **StandardScaler** usa la fórmula $x_{scaled} = \frac{x - \bar{x}}{s}$ para normalizar los datos, donde $\bar{x}$ es la media de la variable y s es su desviación estándar. Esto asegura que cada variable tenga una media de 0 y una desviación estándar de 1, lo que facilita la comparación entre ellas en el análisis de clustering.

3. **Aplicación de k-means:** Se agrupan los datos en k clústeres (supondremos $k = 8$). Para cada registro, se calcula la distancia al centroide de su grupo. Usaremos el algoritmo de k-means de `sklearn.cluster` para realizar esta tarea.
4. **Identificación de atípicos:** Los registros cuya distancia al centroide supera un percentil alto (por ejemplo, el 99 %) se marcan como atípicos.
 - **Atípicos globales:** Potencias inusualmente altas, sin importar el voltaje.
 - **Atípicos contextuales:** Consumos normales pero asociados a voltajes anómalos.
5. **Visualización:** Se genera un gráfico interactivo donde los puntos atípicos se resaltan en rojo, permitiendo explorar visualmente la estructura y los extremos del dataset.

Nota sobre los resultados

Los resultados mostrados a continuación son fijos debido a la naturaleza de LaTeX, pero se puede consultar [este cuaderno de Marimo](#) para ver un análisis interactivo al modificar la cantidad de clústers y el umbral de detección de atípicos.

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 from sklearn.cluster import KMeans
5 from sklearn.datasets import make_blobs
6 import plotly.express as px
7 from sklearn.preprocessing import StandardScaler
8
9 # Cargamos el dataset y seleccionamos/limpiamos las variables de interes
10 df = pd.read_csv('datasets/household_power_consumption.txt', sep=';', nrows= 10000,
11                 low_memory=False)
12 df_limpio = df[['Global_active_power', 'Voltage']].replace('?', np.nan).dropna().astype(
13                 float)
14
15 scaler = StandardScaler()
16 df_scaled = scaler.fit_transform(df_limpio)
17
18 # Aplicamos k-means para agrupar los datos en clusters y detectar atipicos
```

```
16 # Como mencionabamos, vamos a suponer $k=8$. Pero como saber si este es el valor
17 # correcto?
18 kmeans = KMeans(n_clusters=8, random_state=42)
19 df_limpio['Cluster'] = kmeans.fit_predict(df_scaled)
20
21 # Obtenemos las coordenadas de los centroides y calculamos la distancia de cada
22 # punto a su centroide correspondiente
23 centroides = kmeans.cluster_centers_
24 distancias = np.sqrt(np.sum((df_scaled - centroides[df_limpio['Cluster']]) ** 2, axis=1))
25
26 # El porcentaje de los datos mas lejanos a cualquier cluster se consideran atipicos
27 umbral = np.percentile(distancias, 99) # Ajustable segun el nivel de sensibilidad deseado
28 df_limpio['Es_Atipico'] = distancias > umbral
29
30 # Creamos una columna de texto para formatear las leyendas de forma clara
31 df_grafico = df_limpio.copy()
32 df_grafico['Clasificacion'] = df_grafico['Cluster'].astype(str)
33 df_grafico.loc[df_grafico['Es_Atipico'], 'Clasificacion'] = 'Atipico'
34
35 # Mapa de colores: clusteres comunes y rojo para anomalias
36 mapa_colores = {
37     '0': '#1f77b4',      # Azul
38     '1': '#2ca02c',      # Verde
39     '2': '#9467bd',      # Morado
40     '3': '#bcbd22',      # Amarillo
41     '4': '#17becf',      # Cian
42     '5': '#e377c2',      # Rosa
43     '6': '#ff7f0e',      # Naranja
44     '7': '#8c564b',      # Cafe
45     '8': '#7f7f7f',      # Gris
46     '9': '#ffbb78',      # Naranja claro
47     'Atipico': '#d62728' # Rojo para Outliers
48 }
49
50 # Construccion del scatter plot interactivo
51 fig = px.scatter(
52     df_grafico,
53     x='Global_active_power',
54     y='Voltage',
55     color='Clasificacion',
56     color_discrete_map=mapa_colores,
57     symbol='Clasificacion',
58     opacity=0.6,
59     title='Deteccion de Atipicos (K-Medias)',
60     labels={
61         'Global_active_power': 'Potencia Activa Global (kW)',
```

```

62     'Voltage': 'Voltaje (V)'
63 },
64 # Muestra datos limpios al pasar el cursor
65 hover_data={'Cluster': True, 'Es_Atípico': False}
66 )
67
68 fig.update_layout(
69     legend_title_text='Estructura del Dataset',
70     margin=dict(l=40, r=40, t=60, b=40)
71 )

```

Listing 1: Ejecución de K-Means para detección de outliers en consumo eléctrico

Detección de Atípicos (K-Medias)




Figura 7: Visualización de K-Means con detección de atípicos en consumo eléctrico

5.5. La Regla del Codo

¿Y cómo sabemos cual es el valor correcto de k a considerar? El método del codo sirve justo para esto. Funciona de la siguiente manera:

- Ejecutamos k -Means para diferentes valores de k (por ejemplo, desde 1 hasta 10).
- Para cada valor de k , calculamos la inercia.
- Luego, graficamos la inercia en función de k y buscamos el punto donde la disminución de la inercia comienza a ser menos pronunciada, formando una especie de codo (de ahí el nombre).
- El punto resultante suele ser la mejor elección para el número óptimo de clústers, ya que representa un buen equilibrio entre la complejidad del modelo (número de clústers) y la calidad del ajuste (inercia).

5.5.1. Ejemplo usando el método del codo

Veamos como se ve esto aplicado a nuestro dataset anterior. En este caso, vamos a ejecutar k-means para valores de k desde 1 hasta 10 y graficar la inercia para cada uno de estos valores.

```
1 def elbow_method(data, max_clusters=10):
2     """
3     Aplica el metodo del codo para seleccionar el numero optimo de clusters en k-means.
4
5     Parametros:
6     -----
7     data : matriz o matriz dispersa, forma (n_samples, n_features)
8         Los datos de entrada.
9
10    max_clusters : int, opcional (por defecto=10)
11        El numero maximo de clusters a considerar.
12    """
13
14    sum_of_squared_distances = []
15
16    for k in range(1, max_clusters+1):
17        kmeans = KMeans(n_clusters=k)
18        kmeans.fit(data)
19        sum_of_squared_distances.append(kmeans.inertia_)
20
21    # Graficar la curva del codo
22    plt.plot(range(1, max_clusters+1), sum_of_squared_distances, 'bx-')
23    plt.xlabel('Numero de Clusters (k)')
24    plt.ylabel('Suma de las Distancias al Cuadrado')
25    plt.title('Curva del Codo')
26    plt.show
```

```
27  
28 # Aplicar el metodo del codo  
29 elbow_method(df_limpio, max_clusters=10)
```

Listing 2: Ejemplo del método del codo para determinar el número óptimo de clústers




Figura 8: Curva del codo para determinar el número óptimo de clústers en el dataset de consumo eléctrico

Vemos que el valor de la inercia se estabiliza hasta $k = 10$, lo que sugiere que 10 es el número óptimo de clústers para este conjunto de datos y no $k = 8$ como se había supuesto inicialmente. [8]

Referencias

- [1] ¿Qué es el agrupamiento en clústeres *k*-means? Feb. de 2025. URL: https://developers.google.com/machine-learning/clustering/kmeans/overview?hl=es-419#k-means_clustering_algorithm.
- [2] Anblicks. *Types of outliers: Key to accurate data analysis*. 2020. URL: <https://www.anblicks.com/blog/an-introduction-to-outliers-what-are-outliers-types-of-outliers/>.
- [3] *Clustering: Segmentación de Datos para Descubrir Patrones Ocultos*. Ene. de 2026. URL: <https://www.pontia.tech/clustering-que-es/>.
- [4] Amparo Gaona, Gerardo Áviles y Salvador López. “Detección de anomalías”. En: *Minería de datos con R*. 1.^a ed. Las Prensas de Ciencias, 2021, págs. 295-316.
- [5] IBM. *¿Qué es el clustering?* Nov. de 2025. URL: <https://www.ibm.com/es-es/think/topics/clustering>.
- [6] Harold Munoz. *Datos Atípicos (outliers) en machine learning: Impacto, detección y aplicaciones en detección de fraude*. Nov. de 2025. URL: <https://disenet.com/datos-atipicos-outliers-en-machine-learning-impacto-deteccion-y-aplicaciones-en-deteccion-de-fraude/>.
- [7] Jian Pei. *Data Mining - Outlier Detection*. Mayo de 2026. URL: <https://www2.cs.sfu.ca/CourseCentral/459/jpei/21/459OutlierDetection.pdf>.
- [8] Daniel Rodríguez. *Método del Codo (elbow method) para seleccionar el número óptimo de clústeres en k-means*. Mar. de 2025. URL: <https://www.analyticslane.com/2023/06/09/metodo-del-codo-elbow-method-para-seleccionar-el-numero-optimo-de-20clusteres-en-k-means/>.